



BİL 350 MEDİKAL GÖRÜNTÜ İŞLEME


SEGMENTASYON (Bölütleme)

IX. Hafta

Dr. Zeynel Abidin SAMAK

Segmentasyon (Bölütleme)

- Görüntüdeki pikselleri/voxelleri anlamlı yapılar (organlar, lezyonlar, damarlar vb.) olarak sınıflandırma işlemidir.
- Anatomik yapıları izole etmek (örneğin, beyin MR'ında gri/beyaz ayrımı).
- Patolojik oluşumları tespit etmek (örneğin, akciğer BT'sinde lezyon segmentasyonu).




<https://ai.stanford.edu/~syyeung/cvweb/tutorial3.html>

Segmentasyon Türleri

Manuel Segmentasyon



- Uzman radyologlar tarafından elle yapılan segmentasyon.
- **Avantajları:** Yüksek doğruluk, uzman bilgisi içerir.
- **Dezavantajları:** Zaman alıcı, yorucu, kullanıcıya bağımlı.



Segmentasyon Türleri


Yarı-Otomatik Segmentasyon

- Kullanıcının başlangıç noktası belirlemesiyle çalışan algoritmalar.
- Örnek: Region Growing, Active Contours (Snake), Graph Cut.



Segmentasyon Türleri

- **Otomatik Segmentasyon**
- Hiçbir kullanıcı müdahalesine gerek duymadan yapılan segmentasyon.
- Genellikle **Makine Öğrenmesi** veya **Derin Öğrenme** yöntemleri kullanılır.



Segmentasyon Yöntemleri

- **Klasik (Geleneksel) Yöntemler**

- Görüntü işleme tekniklerine dayanır ve piksellerin/voksellerin yoğunluk, doku, şekil gibi düşük seviyeli özelliklerini kullanır.

- **Makine Öğrenmesi Tabanlı Yöntemler**

- Geleneksel yöntemlere kıyasla daha yüksek doğruluk ve otomasyon sağlar. Kmeans, SVM, RF vb. metotlar

- **Derin Öğrenme Tabanlı Yöntemler**


- Özellikle Evrişimli Sinir Ağları (Convolutional Neural Networks - CNNs) kullanarak veriden otomatik olarak hiyerarşik özellikler öğrenir ve segmentasyon yapar.

Klasik Segmentasyon Yöntemleri

Eşikleme (Thresholding):

- Görüntü histogramına bakarak belirli bir yoğunluk eşik değeri veya değerleri belirler. Pikseller/vokseller bu eşik değerine göre farklı sınıflara atanır.
 - Global (tüm görüntü için tek eşik),
 - Yerel/Adaptif (görüntünün farklı bölgeleri için farklı eşikler).
 - Otsu metodu gibi otomatik eşik belirleme algoritmaları vardır.
- Basit, hızlı.
- Gürültüye duyarlı, sadece belirgin yoğunluk farkı olan yapılar için uygun, kısmi hacim etkisi (partial volume effect) sorun yaratabilir.

Eşikleme (Thresholding)






Klasik Segmentasyon Yöntemleri

Bölge Büyütme (Region Growing):

- Bir veya daha fazla "tohum" pikselden/vokselden başlar. Komşu pikselleri/vokselleri, önceden tanımlanmış bir benzerlik kriterine (örn. yoğunluk farkı, doku) göre mevcut bölgeye ekleyerek bölgeyi büyütür.
- Bağlantılı bölgeler oluşturur, kullanımı nispeten kolay.
- Kaynak/işaretleyici noktası seçimine ve durma kriterine duyarlı, gürültüden etkilenebilir.

Bölge Büyütme (Region Growing)



Klasik Segmentasyon Yöntemleri

Kenar Algılama (Edge Detection):

- Görüntüdeki ani yoğunluk değişimlerini (kenarları) tespit eder. Tespit edilen kenarlar birleştirilerek nesne sınırları oluşturulmaya çalışılır.
 - Sobel,
 - Canny,
 - Laplacian filtreleri.
- Nesnelerin sınır bilgisini vurgular.
- Gürültü kenar gibi algılanabilir, kenarlar her zaman kapalı bir sınır oluşturmayabilir, zayıf kenarları kaçırabilir.

Kenar Algılama (Edge Detection)




Klasik Segmentasyon Yöntemleri

Watershed Algoritması:

- Görüntüyü topografik bir harita gibi düşünür (yoğunluk değerleri yükseklik). Görüntüye "su basar" gibi yaparak farklı havzaların (bölgelerin) sınırlarını belirler.
- Bağlantılı bölgeler üretir.
- Gürültüye ve küçük detaylara çok duyarlıdır, aşırı segmentasyona (over-segmentation) yol açabilir.
- Genellikle işaretleyici (marker) kontrollü watershed kullanılır.

Watershed Algoritması



(a) Initial Image




(b) Image as Surface
Topography



(c) Water Flow



(d) Dam Formation




(e) Segmentation Output

Klasik Segmentasyon Yöntemleri

Aktif Konturlar (Active Contours - Snakes & Level Sets):

- Kullanıcı tarafından başlatılan bir eğriyi/yüzeyi (kontur) görüntü üzerindeki nesne sınırlarına doğru hareket ettirir. Hareket, konturun iç enerjisi (düzgünlük, esneklik) ve görüntüden türetilen dış enerji (kenarlar, yoğunluk) tarafından yönlendirilir.
 - Parametrik (Snakes),
 - Geometrik (Level Sets).
- Topoloji değişikliklerine izin verebilir (Level Sets), alt piksel doğruluğu sağlayabilir.
- Başlangıç konturuna ve parametrelere duyarlı, yerel minimumlara takılabilir.

Aktif Konturlar (Active Contours)




Klasik Segmentasyon Yöntemleri

Atlas Tabanlı Segmentasyon:

- Önceden manuel olarak segmente edilmiş bir veya daha fazla referans görüntüyü ("atlas") kullanır.
- Atlas(lar) hedef görüntüye çakıştırılır/eşleştirilir (register edilir) ve atlastaki segmentasyon etiketleri hedef görüntüye dönüştürülür.
- Anatomik ön bilgiyi kullanır, karmaşık yapıları segmente edebilir.
- Doğru bir çakıştırma (registration) algoritması gerektirir, atlas ile hedef görüntü arasındaki anatomik farklılıklar hataya yol açabilir.
- Çoklu atlas kullanımı genellikle doğruluğu artırır.

Atlas Tabanlı Segmentasyon




https://www.researchgate.net/publication/256982001_Multi-Atlas-Based_Segmentation_of_Pelvic_Structures_from_CT_Scans_for_Planning_in_Prostate_Cancer_Radiotherapy

Klasik Segmentasyon Yöntemleri

Grafik Kesme (Graph Cuts):

- Görüntüyü bir graf olarak temsil eder (pikseller/vokseller düğüm, komşuluklar kenar). Segmentasyon problemini, graf üzerinde minimum kesme (min-cut) problemi olarak formüle eder.
- Global optimuma yakın çözümler bulabilir, etkileşimli segmentasyona uygundur.
- Hesaplama maliyeti yüksek olabilir.

Grafik Kesme (Graph Cuts)



a b
c d e

FIGURE 10.52 (a) Image of size 533×566 (301,678) pixels. (b) Image segmented using the k -means algorithm. (c) 100-element superpixel image showing boundaries for reference. (d) Same image without boundaries. (e) Superpixel image (d) segmented using the k -means algorithm. (Original image courtesy of NOAA.)

Makine Öğrenmesi Tabanlı Segmentasyon

- Derin öğrenmenin popülerleşmesinden önce ve bazı durumlarda hala geçerli olan bu yaklaşım, pikselleri/vokselleri veya küçük görüntü parçalarını (patches) sınıflandırmak için geleneksel makine öğrenmesi algoritmalarını kullanır.
- Derin öğrenmeden temel farkı, özelliklerin genellikle *manuel* olarak tasarlanıp çıkarılmasıdır.

Makine Öğrenmesi Tabanlı Segmentasyon


- **Özellik Çıkarımı (Feature Extraction):** Her piksel/voksel veya çevresi (bir pencere/parça) için ayırt edici özellikler hesaplanır. Bu özellikler, segmentasyon yapılacak yapıları tanımlamaya yardımcı olacak bilgiler taşımalıdır.
- **Sınıflandırıcı Eğitimi (Classifier Training):** Etiketlenmiş (hangi pikselin hangi sınıfa ait olduğu bilinen) bir veri seti kullanılarak, çıkarılan özellikler girdi, pikselin sınıfı (örn. tümör, sağlıklı doku, arka plan) çıktı olacak şekilde bir makine öğrenmesi sınıflandırıcısı (örn. SVM, Random Forest) eğitilir.
- **Sınıflandırma (Classification):** Eğitilmiş model, yeni (görülmemiş) görüntülerin pikselleri/vokselleri için hesaplanan özelliklere bakarak her birini ilgili sınıfa atar ve segmentasyon haritasını oluşturur.

Makine Öğrenmesi Tabanlı Segmentasyon

Yaygın Olarak Kullanılan Görüntü Özellikleri:

- **Yoğunluk Özellikleri:** Pikselin/vokselin kendi yoğunluk değeri, çevresindeki piksellerin ortalama/standart sapma/medyan yoğunluğu.
- **Doku Özellikleri (Texture Features):** Görüntüdeki yerel desenleri ve homojenliği tanımlar. Gri Seviye Eş-oluşum Matrisi (GLCM - Gray-Level Co-occurrence Matrix) özellikleri (kontrast, korelasyon, enerji, homojenlik), Gabor filtre yanıtları, Yerel İkili Örüntüler (LBP - Local Binary Patterns) sıkça kullanılır.
- **Şekil ve Konum Özellikleri:** Pikselin/vokselin görüntü içindeki koordinatları, ilgi bölgesinin merkezine uzaklığı gibi bilgiler (özellikle yama tabanlı yaklaşımlarda).
- **Filtre Yanıtları:** Farklı ölçek ve yönlerdeki filtrelerin (örn. Gaussian türevleri, Hessian matrisi tabanlı filtreler) yanıtları, kenar veya çizgi benzeri yapıları vurgulayabilir.

MÖ Görüntü Analizi



Makine Öğrenmesi Tabanlı Segmentasyon

Yaygın Olarak Kullanılan Sınıflandırıcılar:

- **Support Vector Machines (SVM):** Özellikle yüksek boyutlu özellik uzaylarında etkili olabilen, sınıflar arasında optimum ayırım yüzeyini bulmaya çalışan bir algoritma.
- **Random Forests (RF):** Birden çok karar ağacının toplu olarak karar verdiği, genellikle aşırı öğrenmeye (overfitting) karşı daha dayanıklı ve farklı özellik türleriyle iyi çalışabilen bir yöntem.
- **AdaBoost (Adaptive Boosting):** Zayıf sınıflandırıcıları birleştirerek güçlü bir sınıflandırıcı oluşturan bir "boosting" algoritması.
- **K-Nearest Neighbors (k-NN):** Basit, parametrik olmayan bir yöntem; bir pikseli özellik uzayındaki en yakın K komşusunun çoğunluk sınıfına atar.

Makine Öğrenmesi Tabanlı Segmentasyon

- **Avantajları:**

- Klasik eşikleme veya bölge büyütmeye gibi yöntemlerden daha karmaşık ilişkileri modelleyebilir.
- Derin öğrenmeye kıyasla genellikle daha az etiketli veriye ihtiyaç duyabilir.
- Özellik mühendisliği sayesinde probleme özgü bilginin (domain knowledge) modele entegre edilmesi mümkündür.
- Derin öğrenmeye göre daha yorumlanabilir olabilirler.

Makine Öğrenmesi Tabanlı Segmentasyon

Dezavantajları:

- **Özellik Mühendisliği (Feature Engineering):** Performans, büyük ölçüde elle tasarlanan ve seçilen özelliklerin kalitesine bağlıdır. İyi özellikleri bulmak uzmanlık gerektirir ve zaman alıcı olabilir.
- **Sınırlı Temsil Gücü:** Derin öğrenme kadar karmaşık ve hiyerarşik özellikleri otomatik olarak öğrenemezler. Özellikle çok değişken ve karmaşık doku/yapıların olduğu durumlarda performansları DL'nin gerisinde kalabilir.
- **Mekansal/Uzamsal (Spatial) Bilgi Kaybı:** Piksel bazlı sınıflandırma, pikseller arasındaki mekansal ilişkiyi (komşuluk, yapısal bütünlük) tam olarak yakalayamayabilir. Bunu telafi etmek için genellikle Markov Rastgele Alanları (MRF) veya Koşullu Rastgele Alanları (CRF) gibi son işleme (post-processing) adımları eklenir.

Derin Öğrenme Tabanlı Segmentasyon

- Son yıllarda medikal görüntü segmentasyonunda devrim yaratan yaklaşım olmuştur.
- Çok katmanlı yapay sinir ağları (özellikle CNN'ler ve Transformerlar) kullanarak doğrudan görüntülerden **karmaşık** ve **hiyerarşik özellikleri** öğrenmek ve bu özellikleri kullanarak piksel/voksel bazında sınıflandırma (segmentasyon) yapmaktır.


Derin Öğrenme Tabanlı Segmentasyon

- **Tam Evrişimli Ağlar (Fully Convolutional Networks - FCN):**
Geleneksel CNN'lerdeki tam bağlantılı katmanları evrişimli katmanlarla değiştirerek uçtan uca (end-to-end) piksel bazında tahmin yapmayı sağlar. Farklı çözünürlükteki özellik haritalarını birleştirir.

Derin Öğrenme Tabanlı Segmentasyon

- **U-Net:** Medikal görüntü segmentasyonu için özel olarak tasarlanmış ve çok popüler olmuş bir FCN türevidir. Simetrik bir kodlayıcı (encoder - özellik çıkarımı, daralan yol) ve kod çözücü (decoder - çözünürlüğü artırma, genişleyen yol) yapısına sahiptir. Kodlayıcı ve kod çözücü katmanları arasında "atlama bağlantıları" (skip connections) bulunur. Bu bağlantılar, yüksek çözünürlüklü detayların korunmasına yardımcı olur.

U-Net



<https://lmb.informatik.uni-freiburg.de/Publications/2015/RFB15a/>

U-Net

- **Daralan Yol (Encoder/Contracting Path):**


- Görüntüden özellikleri çıkarır ve bağlamı (context) öğrenir.
- Max-pooling işlemleri ile boyut küçülürken özellik haritası derinleşir. "Ne" sorusuna cevap verir.

- **Genişleyen Yol (Decoder/Expanding Path):**

- Çıkarılan özellikleri orijinal görüntü boyutuna geri getirir. "Nerede" sorusuna cevap verir.

- **Atlama Bağlantıları (Skip Connections):**

- U-Net'in en kritik özelliğidir.
- Encoder'daki yüksek çözünürlüklü özellik haritalarını, Decoder'daki karşılık gelen katmanlara kopyalar. Bu, konum bilgisinin kaybolmasını engeller ve sınırların çok hassas çizilmesini sağlar.




<https://lmb.informatik.uni-freiburg.de/Publications/2015/RFB15a/>

Derin Öğrenme Tabanlı Segmentasyon

- **U-Net Türevleri ve Diğerleri:** V-Net (3D U-Net), UNet++, Attention U-Net, SegNet, DeepLab serisi gibi birçok farklı mimari geliştirilmiştir.
- Bunlar genellikle U-Net'in temel prensiplerini farklı modifikasyonlarla (dikkat mekanizmaları, farklı blok yapıları vb.) geliştirir.
- **nnU-Net:**
 - Manuel hiperparametre ayarına gerek duymayan, otomatik konfigürasyon yapan bir çerçevedir.
 - Birçok medikal segmentasyon yarışmasında birinciliği almış, "kendi kendini yapılandıran" bir U-Net ekosistemidir.



Derin Öğrenme Tabanlı Segmentasyon

- **V-Net ve 3D U-Net**
- Medikal görüntüler genellikle 3 boyutludur (Hacimsel veriler - Voxel). 2D kesitleri tek tek işlemek yerine, 3D evrişim işlemleri kullanarak derinlik (Z ekseni) bilgisini de modelleyen mimarilerdir.
- Özellikle MR ve BT taramaları için kritik öneme sahiptirler.




Derin Öğrenme Tabanlı Segmentasyon

- **Attention U-Net (Dikkat Mekanizmaları)**
- Standart U-Net, tüm özellik haritasına eşit önem verir.
- Attention U-Net ise bir "dikkat kapısı" (attention gate) kullanarak modelin sadece hedef yapıya (örneğin sadece pankreasa) odaklanmasını, gereksiz arka plan bilgilerini ise baskılamasını sağlar.



Derin Öğrenme Tabanlı Segmentasyon

- **Vision Transformers (Swin-UNet, TransUNet)**
- Son yılların en güncel yaklaşımıdır.
- Evrişimli ağlar lokal (yerel) özelliklere odaklanırken, Transformer tabanlı modeller "Self-Attention" mekanizması sayesinde görüntünün tamamındaki global (küresel) ilişkileri aynı anda yakalayabilir.



Derin Öğrenme Tabanlı Segmentasyon

Avantajları:

- Yüksek doğruluk ve performans (özellikle yeterli veri varsa)
- Karmaşık desenleri ve dokuları öğrenebilme.
- Otomatik özellik çıkarımı (manuel özellik mühendisliği gerektirmez).
- Uçtan uca öğrenme.

Derin Öğrenme Tabanlı Segmentasyon

Dezavantajları:

- **Veri İhtiyacı:** Genellikle büyük miktarda, uzmanlar tarafından dikkatlice etiketlenmiş (segmente edilmiş) veriye ihtiyaç duyar. Bu veriyi oluşturmak zaman alıcı ve maliyetlidir.
- **Hesaplama Maliyeti:** Ağların eğitimi güçlü GPU'lar gerektirir ve uzun sürebilir.
- **Yorumlanabilirlik:** Derin öğrenme modelleri genellikle "kara kutu" (black box) olarak görülür, yani neden belirli bir segmentasyon kararı verdiklerini anlamak zor olabilir.
- **Genelleme Sorunları:** Farklı tarayıcılardan, protokollerden veya hasta popülasyonlarından gelen verilere genelleme yapmak zor olabilir.

Segmentasyon Performansının Değerlendirilmesi

Piksel/Voksel Bazlı Metrikler:

- **Doğruluk (Accuracy):** Doğru sınıflandırılan piksel/voksel oranı. Sınıf dengesizliği (örn. küçük bir lezyonun segmentasyonu) durumunda yanıltıcı olabilir.
- **Duyarlılık (Sensitivity / Recall / True Positive Rate):** Gerçek pozitiflerin (doğru segmente edilen hedef bölge pikselleri) ne kadarının algoritma tarafından bulunduğunu ölçer. $TP / (TP + FN)$

Segmentasyon Performansının Değerlendirilmesi

Piksel/Voksel Bazlı Metrikler:

	Predicted Positive	Predicted Negative	
Actual Positive	TP <i>True Positive</i>	FN <i>False Negative</i>	Sensitivity $\frac{TP}{(TP + FN)}$
Actual Negative	FP <i>False Positive</i>	TN <i>True Negative</i>	Specificity $\frac{TN}{(TN + FP)}$
	Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

Segmentasyon Performansının Değerlendirilmesi

Piksel/Voksel Bazlı Metrikler:

- **Özgüllük (*Specificity / True Negative Rate*):** Gerçek negatiflerin (doğru şekilde hedef bölgeye ait olmadığı belirlenen pikseller) ne kadarının algoritma tarafından doğru sınıflandırıldığını ölçer. $TN / (TN + FP)$
- **Kesinlik (*Precision*):** Algoritmanın pozitif olarak tahmin ettiği piksellerin ne kadarının gerçekten pozitif olduğunu ölçer. $TP / (TP + FP)$

Segmentasyon Performansının Değerlendirilmesi

- Segmentasyon algoritmalarının başarısını ölçmek için çeşitli metrikler kullanılır. En yaygın olanlar şunlardır:


Örtüşme Metrikleri:

- *Dice Katsayısı* (*Dice Coefficient / Sørensen-Dice Index / F1 Score*): En popüler metriklerden biridir. Tahmin edilen segmentasyon (P) ile gerçek (manuel) segmentasyon (G) arasındaki örtüşmeyi ölçer. Değer aralığı $[0, 1]$ 'dir (1 mükemmel örtüşme).
 - $Dice = (2 * |P \cap G|) / (|P| + |G|)$
- *Jaccard İndeksi* (*Intersection over Union - IoU*): Dice'a benzer şekilde örtüşmeyi ölçer.
 - $IoU = |P \cap G| / |P \cup G|$ (Dice ile $Dice = 2 * IoU / (1 + IoU)$ ilişkisi vardır)

Segmentasyon Performansının Değerlendirilmesi

- Segmentasyon algoritmalarının başarısını ölçmek için çeşitli metrikler kullanılır. En yaygın olanlar şunlardır:
- **Dice Benzerlik Katsayısı (Dice Similarity Coefficient - DSC)**
- Tahmin edilen maske (P) ile gerçek maske (Ground Truth, G) arasındaki örtüşmeyi ölçer.
- $DSC = \frac{2|G \cap P|}{|G| + |P|}$
- *Jaccard İndeksi (Intersection over Union - IoU)*: Dice'a benzer şekilde örtüşmeyi ölçer.
- $IoU = \frac{|G \cap P|}{|G \cup P|}$

Dice & IoU



Segmentasyon Performansının Değerlendirilmesi

Yüzey Mesafesi Metrikleri

- Sınırların doğruluğunu değerlendirmek için kullanılır.
- **Hausdorff Mesafesi (Hausdorff Distance - HD):** İki küme (tahmin edilen ve gerçek sınırlar) arasındaki maksimum mesafeyi ölçer. Aykırı/uç değerlere duyarlıdır. Genellikle 95. persentil (%95 HD) kullanılır.
- **Ortalama Yüzey Mesafesi (Average Surface Distance - ASD):** İki yüzey arasındaki ortalama mesafeyi ölçer.

Kayıp Fonksiyonları

- Medikal segmentasyonda sınıf dengesizliği kritik bir sorundur (örn. tümör pikselleri << arka plan pikselleri). Bu nedenle özel kayıp fonksiyonları kullanılır:
- **Dice Loss:** Dice katsayısını maksimize eder; küçük yapılarda Cross-Entropy'den daha kararlıdır. $L_{dice} = 1 - (2 | P \cap G |) / (| P | + | G |)$
- **Focal Loss:** Yanlış sınıflandırılan zor örneklerle daha fazla ağırlık verir; sınıf dengesizliğini hafifletir.
- **Tversky Loss / Focal Tversky Loss:** Yanlış negatifler ile yanlış pozitifler arasındaki dengeyi ayarlanabilir α , β parametreleriyle kontrol eder.
- Pratikte genellikle Dice + Cross-Entropy kombinasyonu kullanılır.

Alıştırmalar

- https://github.com/Project-MONAI/tutorials/blob/main/vista_2d/vista_2d_tutorial_monai.ipynb
- https://colab.research.google.com/drive/1xsEQb-GilPMbhecle31dsd8jEPYi7_Qa?usp=sharing#scrollTo=1QkOWOvlgGrB
 - <https://colab.research.google.com/drive/1R8OoIWS9B9V5IxOF9ExHQk2XAEzKd70-?usp=sharing>
- https://docs.opencv.org/4.x/d3/db4/tutorial_py_watershed.html

Ödev

- Yukarda verilen segmanstasyon yöntemlerinden birini seçerek projenizde kullanacağınız görüntülere uygulayınız.
- Rapor halinde;
 - Kullandığınız yöntemi detaylıca açıkla,
 - Kullandığın kodu ekle
 - Segmentasyon performansını nitel ve nicel verilerle göster.



Kaynakça

1. Paulsen and Moeslund, Introduction to Medical Image Analysis, 2020
2. Gonzalez and Woods, Digital Image Processing, 4rd Edition, 2017
3. <https://ai.stanford.edu/~syYeung/cvweb/tutorial1.html>



DERS SONU

Gelecek Hafta:

Dr. Zeynel Abidin SAMAK